



ESTADO DE MATO GROSSO
SECRETARIA ESTADO DE CIÊNCIA, TECNOLOGIA E INOVAÇÃO
UNIVERSIDADE DO ESTADO DE MATO GROSSO
CAMPUS UNIVERSITÁRIO DE BARRA DO BUGRES
FACULDADE DE CIÊNCIAS EXATAS E TECNOLÓGICAS
CURSO DE CIÊNCIA DA COMPUTAÇÃO



KLEVERSON SILVA JARA

O IMPACTO DA IA PREDITIVA NA GESTÃO EMPRESARIAL

BARRA DO BUGRES – MT
2025

KLEVERSON SILVA JARA

O IMPACTO DA IA PREDITIVA NA GESTÃO EMPRESARIAL

Projeto de pesquisa apresentado ao Departamento de Ciência da Computação da Universidade do Estado de Mato Grosso – UNEMAT, como pré-requisito parcial da disciplina de Trabalho de Conclusão de Curso I, sob orientação do professor Dr. LUCIANO ZAMPERETTI WOLSKI.

BARRA DO BUGRES

2025

SUMÁRIO

PROJETO DE PESQUISA.....	5
1 TEMA.....	5
2 DELIMITAÇÃO DO TEMA	5
3 PROBLEMA.....	5
4 HIPÓTESE.....	5
5 OBJETIVOS	5
5.1 Objetivo geral	5
5.2 Objetivos específicos	5
6 JUSTIFICATIVA.....	6
7 FUNDAMENTAÇÃO TEÓRICA.....	7
7.1 Inteligência artificial	7
7.2 <i>Machine learning</i>	8
7.3 <i>Deep Learning</i> (DL).....	10
7.4 <i>Business Intelligence</i>	11
7.4.1 Etapas do BI	12
7.5 <i>Data science</i>	13
8. METODOLOGIA.....	13
8.1 Enquadramento Metodológico.....	14
8.2 Design Science Research Methodology	15
9 CRONOGRAMA	19
10 ORÇAMENTO.....	21

LISTA DE ABREVIATURAS

BI	<i>Business Intelligence</i>
DDD	<i>Data-driven decision-making</i>
DM	<i>Data Mining</i>
DSR	<i>Design Science Research</i>
DSRM	<i>Design Science Research Methodology</i>
DL	<i>Deep Learning</i>
IA	Inteligência Artificial
ML	<i>Machine Learning</i>
MIT	<i>Massachusetts Institute of Technology</i>
PO	Pesquisa Operacional
RNA	Redes Neurais Artificiais
RNS	Redes Neurais Simuladas
SSD	Sistema de Suporte à Decisão

PROJETO DE PESQUISA

1 TEMA

O impacto da Inteligência Artificial preditiva na gestão empresarial

2 DELIMITAÇÃO DO TEMA

O impacto da Inteligência Artificial preditiva na análise financeira e projeção de cenários econômicos em pequenas empresas.

3 PROBLEMA

As empresas frequentemente enfrentam dificuldades para tomar decisões assertivas e antecipar os impactos dessas decisões nos negócios. Até que ponto a Inteligência Artificial preditiva pode apoiar os gestores nesse processo decisório, fornecendo previsões que orientem a melhor escolha estratégica?

4 HIPÓTESE

Organizações que utilizam Inteligência Artificial apresentam maior eficiência na alocação de recursos e maior agilidade na adaptação às mudanças de mercado em comparação às que não utilizam.

5 OBJETIVOS

5.1 Objetivo geral

Realizar o desenvolvimento e treinamento de um modelo usando Inteligência Artificial preditiva na busca de resultados, assim comprovando o apoio a tomada de decisões no âmbito da gestão empresarial.

5.2 Objetivos específicos

- Identificar técnicas e métodos preditivos aplicáveis à gestão de negócios.

- Coletar e analisar um base de dados empresariais como histórico de vendas com potencial preditivo.
- Avaliar a eficácia de modelos de Inteligência Artificial preditiva através de testes em cenários simulados de decisão empresarial.

6 JUSTIFICATIVA

Inteligências Artificiais (IA) já existem no mercado a quase 50 anos, mas foram nos últimos 6 anos que começaram a ser palco de interesse das pessoas através das versões generativas tais como o ChatGPT da OpenAI e o Gemini da Google, é claro entre outros que permitiram uma nova gama de variedades que incluem escrita e áudios gerados, até mesmo no seu uso mais recente, a geração de vídeos que são gerados totalmente de forma automática.

Elas não são limitadas somente a um assistente virtual 24h, hoje as Inteligências Artificiais atuam em todos os ramos da indústria, desde um modelo de assistente onde se tira dúvidas de determinado produto ou serviço, há um sistema que monitora e analisa dados sobre alimentos para assim determinar melhores práticas que tornam o plantio mais eficiente, isso entre outras inúmeras utilizações dentro das indústrias.

Ao longo da última década, é possível notar uma transformação significativa no meio empresarial, que se é caracterizado por um ambiente competitivo e dinâmico que constantemente se vê pressionado a buscar novas inovações, sejam elas em novas técnicas de vendas, ou processos automatizados que podem agilizar tarefas do cotidiano. Segundo uma pesquisa realizada pelo Sebrae, a automação de processos pode concluir tarefas até 70% mais rápido que uma pessoa, tornando-a mais eficiente que os humanos.

Como resultado, as operações se tornam muito mais eficientes. Mesmo com a onda de possibilidades que a tecnologia vem proporcionando ao mercado, ainda sim uma grande incógnita surge ao final de cada dia, que nada mais é da incerteza de com as decisões tomadas poderão impactar o futuro. Com isso empresas do mundo todo estão cada vez mais adotando para dentro de suas culturas o uso das IAs nos processos internos, um estudo realizado pela McKinsey no ano de 2024 foi capaz de determinar que dentro do espaço de um ano entre 2023 para 2024 houve um salto de 50% para 72% no uso das IAs em diversas áreas dentro das empresas.

O uso de IA preditiva na gestão estratégica permite que decisões sejam tomadas com maior embasamento e precisão, afinal são “funcionários” que trabalham sem descanso todos os dias analisando dados que são gerados durante as operações. Gestores podem antecipar cenários

futuros e avaliar riscos com antecedência, ajustando planos de ação antes que problemas ocorram ou aproveitando oportunidades assim que se delineiam.

Organizações orientadas por dados tendem a estar um passo à frente, pois conseguem reagir rapidamente às mudanças do mercado e às necessidades dos clientes. Além disso, decisões que são tomadas com base em informações detalhadas acabam resultando em uma melhora no desempenho empresarial: processos internos tornam-se mais eficientes, recursos são alocados de forma otimizada e estratégias de vendas ou investimento apresentam maior chance de sucesso.

Com base nisso é perceptível o atual caminho que as empresas estão tomando em relação as IA, cada vez mais a tecnologia deixa de ser um problema e se torna uma forma de auxílio para empresários e pessoas comuns.

7 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta a fundamentação teórica envolvida na elaboração desta monografia, contendo os temas inteligência artificial, *machine learning*, *deep learning*, *business intelligence* e *data science*, como demonstram as seções a seguir.

7.1 Inteligência artificial

A IA consiste em uma área da computação onde a dedicação é voltada para o desenvolvimento e aprimoramento de máquinas, que em sua maioria consistem em realizar tarefas que normalmente exigiriam a inteligência humana (Gurkaynak; Yilmaz; Haksever, 2016). A IA permite que os sistemas técnicos percebam o ambiente que os rodeia, e com isso lidando e resolvendo problemas, no sentido de alcançar um objetivo. Esse feito se dá a capacidade das IAs poderem adaptar o seu comportamento, até certo ponto, com uma análise dos efeitos de ações anteriores, é quase como se a máquina de certa forma estivesse pensando.

A primeira evidencia mais famosa foi proposta pelo matemático britânico Alan Mathison Turing em 1954 através do teste de Turing, que consistia em um experimento para determinar se uma máquina poderia “pensar”, onde um computador passaria no teste se após uma série de perguntas um entrevistador humano não conseguisse determinar se as respostas seriam humanas ou de um computador (Russell; Norvig, 2022).

Essa pesquisa constante em cada vez mais termos máquinas capazes de competir com a mente humano acabou levando ao desenvolvimento de inúmeras técnicas e abordagens que levaram as IAs a outro patamar. Dentre elas podemos que os avanços mais notáveis foram as

redes neurais, os algoritmos de aprendizagem de máquina, e os sistemas especialistas (Chollet, 2018).

Redes Neurais pode ser um modelo, ou programa, de aprendizado de máquina que é capaz de tomar decisões de uma forma que se assemelha ao de um cérebro humano, capaz de utilizar processos que imitam os neurônios biológicos e a maneira como eles trabalham juntos para identificar fenômenos, ponderando opções para assim chegar em conclusões (Huang, 2009).

Elas dependem dados de treinamento para que possam aprender e melhorar a precisão ao longo que o tempo se passa, permitindo assim classificar e agrupar em velocidade elevada, dados de inúmeras tarefas, que incluem reconhecimento de fala e voz, e a compreensão de imagens, um dos exemplos mais conhecidos de uma rede neural é o algoritmo de pesquisa do Google. As redes neurais são algumas vezes chamadas de Redes Neurais Artificiais (RNA) ou Redes Neurais Simuladas (RNS) (Huang, 2009). Elas são um subconjunto de *machine learning* e estão no coração dos modelos de *deep learning*. Os algoritmos de aprendizagem por sua vez permitem que as redes neurais através de treinamento possam calcular resultados mais precisos ajustando os parâmetros para que possam representar o mundo de modo mais realista.

Diferentes algoritmos analisam dados de maneiras diferentes. Geralmente, eles são agrupados pelas técnicas de *machine learning* para as quais são usados: aprendizado supervisionado, aprendizado não supervisionado e aprendizado de reforço. Os algoritmos usados com mais frequência usam a regressão e a classificação para prever categorias de destino, encontrar pontos de dados incomuns, prever valores e descobrir semelhanças (Mohri; Rostamizadeh; Talwalkar, 2018).

7.2 Machine Learning (ML)

O ML é um subcampo da IA e emerge como uma poderosa ferramenta computacional capaz de extrair conhecimento de dados e gerar modelos preditivos sem a necessidade de programação explícita para cada regra ou padrão (Mohri; Rostamizadeh; Talwalkar, 2018). Enquanto humanos aprendem através de experiência, será que computadores podem fazer o mesmo? Em sistemas de computador, elas existem na forma de dados, e a principal tarefa do ML é desenvolver algoritmos de aprendizagem que cria modelos a partir dos dados.

Quando o agente é um computador, chamamos isso de aprendizado de máquina (*machine learning*): o computador observa um conjunto de dados, constrói um modelo com base nesses dados e utiliza esse modelo tanto como uma hipótese sobre o mundo quanto como

um software capaz de resolver problemas (Russell; Norvig, 2022). A tecnologia de ML tornou-se uma parte padrão da engenharia de software. Sempre que se desenvolve um sistema de software mesmo que ele não seja considerado um agente de IA há componentes do sistema que podem potencialmente ser aprimorados com aprendizado de máquina.

Por exemplo, um software criado para analisar imagens de galáxias sob lentes gravitacionais foi acelerado em um fator de 10 milhões por meio de um modelo baseado em ML (Hezaveh; Levasseur; Marshall, 2017). Quando se pesquisa sobre inteligência artificial é inevitável se deparar com dois temas o ML e o Deep Learning (DL). Como o DL e o ML tende a ser usados de forma intercambiável, vale a pena observar as nuances entre os dois.

A forma como o DL e o aprendizado de máquina diferem está na maneira como cada algoritmo aprende. O ML "profundo" pode usar conjuntos de dados rotulados, também conhecidos como aprendizado supervisionado, para informar seu algoritmo, mas não exige necessariamente um conjunto de dados rotulado (Mohri; Rostamizadeh; Talwalkar, 2018).

O processo de DL pode ingerir dados não estruturados em sua forma bruta (por exemplo, texto ou imagens) e pode determinar automaticamente o conjunto de funcionalidades que distinguem diferentes categorias de dados umas das outras. Isso elimina parte da intervenção humana necessária e permite o uso de grandes quantidades de dados.

Os modelos de ML se enquadram em três categorias principais: Aprendizado Supervisionado, Não Supervisionado e Aprendizado de Reforço.

- No Aprendizado Supervisionado o agente observa pares de entrada e saída e aprende uma função que mapeia a entrada para a saída. Por exemplo, as entradas podem ser imagens capturadas por uma câmera, cada uma acompanhada de uma saída indicando “ônibus”, “pedestre” etc. Nesse caso, um conjunto de valores de saída pode ser obtido pelo próprio agente a partir de suas percepções (depois do evento); o ambiente atua como o professor, e o agente aprende uma função que mapeia estados para distâncias de frenagem (Russell; Norvig, 2022).
- No Não Supervisionado os algoritmos descobrem padrões ocultos ou agrupamentos de dados sem a necessidade de intervenção humana. A tarefa mais comum de aprendizado não supervisionado é o agrupamento (*clustering*): identificar conjuntos potencialmente úteis de exemplos de entrada.
- Já em Aprendizado de Reforço o agente aprende a partir de uma série de reforços, recompensas e punições. Por exemplo, ao final de uma partida de xadrez, o agente é informado se venceu (recompensa) ou perdeu (punição). Cabe ao agente determinar

quais das ações anteriores ao reforço foram mais responsáveis pelo resultado e ajustar seu comportamento para buscar mais recompensas no futuro (Russell; Norvig, 2022).

7.3 Deep Learning (DL)

DL é o campo do ML onde os computadores são capazes de aprender a representar e reconhecer coisas gradualmente utilizando redes neurais profundas (Teofili, 2019). Com o repentino aumento da internet, um problema fundamental acabou se tornando ainda mais crítico atualmente, que é, como identificar uma informação que satisfaça as necessidades do usuário através de muitas informações.

O objetivo é apresentar ao usuário apenas as informações de interesse e relevância, no momento, lugar e contexto adequados. Atualmente, dois tipos de paradigmas de acesso à informação buscam e recomendação são amplamente utilizados em diversos cenários.


Na busca, os documentos (por exemplo, páginas da web, postagens no Twitter ou produtos de e-commerce) são primeiro pré-processados e indexados em um mecanismo de busca. Em seguida, o mecanismo recebe uma consulta (um conjunto de palavras-chave) do usuário. Essa consulta descreve a necessidade de informação do usuário. Documentos relevantes são recuperados do índice, comparados com a consulta e classificados de acordo com sua relevância para ela.

Por exemplo, se um usuário estiver interessado em notícias sobre computação quântica, ele pode enviar a consulta “computação quântica” a um mecanismo de busca e receber artigos sobre esse tema (Xu; He; Li, 2020).

Diferente da busca, um sistema de recomendação normalmente não recebe uma consulta explícita. Em vez disso, ele analisa o perfil do usuário (por exemplo, dados demográficos e contextuais) e suas interações históricas com itens, para então recomendar conteúdos ao usuário.

Como mostrado na Figura 1 as características dos usuários e dos itens são previamente indexadas e armazenadas no sistema. Os itens são classificados de acordo com a probabilidade de o usuário se interessar por eles.

Figura 1: Processo de recomendação.



Fonte: Adaptado de Maxwell, 2018

A busca e a recomendação já foram combinadas em algumas aplicações práticas, compartilhando muitas tecnologias devido às suas semelhanças na correspondência. Alguns problemas de busca podem ser resolvidos usando técnicas de recomendação (Xu; He; Li, 2020) e vice versa levando em consideração a base na correspondência.

7.4 Business Intelligence

Business Intelligence (BI), é um sistema de suporte à decisão (SSD) orientado por dados que combina coleta, armazenamento e gestão do conhecimento com análise para fornecer subsídios ao processo de tomada de decisão (Burstein; W. Holsapple, 2008). O termo *BI*, surgiu na década de 80 no *Gartner Group* e faz referência ao processo inteligente de coleta, organização análise, compartilhamento e monitoração de dados contidos em *Data Warehouse*¹ / *Data Mart*², gerando informações para o suporte a tomada de decisões no ambiente de negócios (Primak, 2008). Durante os primórdios da análise de dados, os dados costumavam provir de especialistas de cada área através de processos manuais como revistas ou enquetes para construir modelos matemáticos ou baseados em conhecimento para solucionar problemas restritos de otimização. Esses modelos de apoio à decisão costumavam ser chamados de pesquisa operacional (PO) (Sharda; Delen; Turban, 2019).

A prática comum das empresas para conseguir esses dados eram através de múltiplos sistemas de informação desmembrados e que eram feitos sob medida para capturar dados transacionais de diferentes departamentos ou funções dentro da organização. Foi então que na década de 80 esses sistemas foram unificados e integrados na organização com um todo,

¹ Sistema de gerenciamento de dados projetado para ativar e fornecer suporte às atividades de BI

² Versão mais simples do *Data Warehouse* com foco em um único assunto ou linha de negócio

seguindo o modelo atualmente chamado de planejamento de recursos empresariais (ERP – *enterprise resource planning*).³

Com essa mudança agora todos os dados de cada canto da empresa são coletados e integrados e coletados de forma consistente, possibilitando assim todas da empresa terem acesso a apenas uma única verdade quando e onde for necessária.

Com a evolução da tecnologia o BI acabou ganhando uma série de ferramentas como o próprio EIS⁴ e as soluções SSD, Planilhas eletrônicas, Geradores de Consultas e de Relatórios, Data Marts, Data Mining (DM), Ferramentas OLAP⁵, entre outras, que tem como o objetivo facilitar e agilizar a atividade comercial.

7.4.1 Etapas do BI

Seguindo quatro etapas principais o BI segue transformando dados brutos em insights⁶ fáceis para todos os membros de uma organização possam utilizar. Os três primeiros: coleta, análise e visualização de dados, preparam o cenário para a etapa final de tomada de decisão (Sharda; Delen; Turban, 2017).

A etapa 1 consiste em coletar dados e transformar dados de várias fontes normalmente usando o método ETL⁷ que agregam dados estruturados e não estruturados de várias fontes. Os dados acabam sendo remodelados antes de serem armazenados em um local central, para que posteriormente possam ser consultados facilmente.

Na etapa 2 são então descobertas tendências e inconsistências, normalmente através de mineração de dados usando automação para analisar dados com o objetivo de encontrar padrões e exceções que fornecem informações sobre o estado atual dos negócios.

Já na etapa 3 é usada a visualização de dados com fim de apresentar as descobertas, para então facilitar a compreensão e o compartilhamento das descobertas.

E por fim na etapa 4 são tomadas medidas com base nos insights em tempo real, permitindo ajustes e alterações estratégicas de longo prazo que acabam eliminando ineficiências, adaptam-se a turnos do mercado, corrigem problemas de fornecimento e resolvem problemas do cliente.

³ Software que ajuda as organizações a otimizarem seus principais processos de negócios

⁴ É um sistema de informação abrangente e integrado, projetado para gerenciar as informações e os processos de uma empresa em todas as áreas funcionais

⁵ Soluções projetadas para análise multidimensional de dados em ambientes como Data Warehouse

⁶ Compreensão intuitiva ou uma nova perspectiva que antes não era evidente

⁷ extração, transformação e carregamento

7.5 Data science

O termo *data Science* (DS) acabou sendo discutido pela primeira vez em meados de 1990, em discussões que visavam juntar estatísticos com cientistas da computação no intuito de trazer um rigor matemático maior para a análise computacional de grande amontado de dados. O DS pode ser definido como um conjunto de princípios fundamentais que apoiam e orientam a extração de informações e conhecimento a partir de dados (Provost; Fawcett, 2013), através de série de princípios, definição de problemas e algoritmos que servem para gerar processos de extração intuitiva da obtenção de padrões derivadas dos dados, assim gerando insights que podem ser usados para orientar a tomada de decisão e o planejamento estratégico, muito dos elementos do DS foram desenvolvidos em campos relacionados, tais como o ML e DM.

Um desses processos dentro do DS leva o nome de *Data driven decision* (DDD), onde se refere ao processo da tomada de decisão sendo baseado na análise dos dados, ao invés da pura intuição (Provost; Fawcett, 2013). Um exemplo desse processo seria a de um fazendeiro que poderia comprar quantidades de sementes para a sua terra baseada puramente em sua longa experiência no campo. Ou ele poderia realizar uma análise de dados para saber a precisão exata de sementes.

A eficácia do DDD vem sendo apurada em numeras pesquisas, uma delas realizada pelo economista Erik Brynjolfsson e seus colegas no MIT⁸, que visava demonstrar a eficácia do DDD e como ele poderia afetar o desempenho de empresas (Brynjolfsson; Hitt; Kim, 2011). O estudo realizado mediu o quanto as empresas utilizavam dados para tomada de decisões, e estatisticamente quanto mais dados gerados mais eficiente a operação se tornava, havendo um aumento de 4%-6% na produtividade através do DDD.

8. METODOLOGIA

A presente seção aborda a metodologia de pesquisa adotada neste projeto. As seções a seguir apresentam o enquadramento metodológico da pesquisa, classificando-a quanto à

⁸ Instituto de Tecnologia de Massachusetts

natureza, aos objetivos e aos procedimentos. Também será apresentada a *Design Science Research Methodology*.

8.1 Enquadramento Metodológico

Essa pesquisa pode ser caracterizada como tecnológica, visto que tem o objetivo a produção de artefatos e processos. O principal campo de ação da pesquisa tecnológica é a mudança, e os planos gerados para fazer a mudança são considerados inovações, ou seja, cada processo de mudança requer metodologias tecnológicas para gerenciá-lo, tais como novas formas de trabalho (Rusu et al., 2024).

A pesquisa será conduzida com uma abordagem quantitativa, que é a forma para testar teorias objetivas através de variáveis mensuráveis, examinando a relação entre elas para que os dados possam ser analisados por procedimentos estatísticos. A abordagem quantitativa é caracterizada pela utilização de técnicas padronizadas de coleta de dados, como questionários, testes e escalas de avaliação, e conjuntos de dados para determinada tarefa, e pela análise estatística dos dados coletados (Gil, 2008). A coleta de dados é realizada mediante instrumentos de medição que devem representar verdadeiramente as variáveis da pesquisa. As respostas obtidas são codificadas e transferidas para uma matriz de dados e preparadas para análise.

Já os objetivos, a pesquisa se enquadram no caráter exploratório, pois tem pretende proporcionar uma visão geral, de tipo aproximativo, acerca de determinado fato. Realiza-se esse tipo de pesquisa especialmente quando o tema escolhido é pouco explorado, tornando-se difícil formular hipóteses precisas e operacionalizáveis sobre ele (Gil, 2008).

Segundo Gil (2008), parte dos estudos exploratórios pode ser definida como pesquisas bibliográficas. Em relação aos procedimentos, esta tese se caracteriza como uma pesquisa bibliográfica, pois se desenvolve com base no acervo de documentos já existentes, composto principalmente de artigos científicos e livros. A pesquisa bibliográfica tem como vantagem primordial permitir ao pesquisador a cobertura de uma série de fenômenos muito mais ampla do que aquela que poderia pesquisar diretamente (Gil, 2008).

A pesquisa também tem relação com a *Desing Science*, que se destina a criar conhecimento, e não apenas aplicá-lo, isso significa que é uma ciência voltada para o *design*, centrada em desenvolver e projetar soluções para aperfeiçoar sistemas existentes, ou mesmo a criação de artefatos que contribuam para o melhor comportamento humano.

Com isso se tornando a base para o *Desing Science Research* (DSR), que representa o método adotado para a sistematização desta pesquisa. O método DSR é uma estratégia de

pesquisa capaz de orientar tanto a construção do conhecimento quanto aprimorar as práticas em sistemas de informação e de várias disciplinas relacionadas ao campo gerencial e tecnológico da ciência da informação (Peffer et al., 2007).

Diante do exposto, apresentam-se na próxima seção os princípios e os fundamentos da DSR que conduzem para determinada metodologia a ser seguida no desenvolvimento desta pesquisa.

8.2 *Design Science Research Methodology*

A *Design Science Research* (DSR) implica construir, investigar, validar e avaliar artefatos com o propósito de resolver novos problemas práticos, tais como constructos, frameworks, modelos, métodos e instâncias de sistema de informação. Engloba também o estudo de métodos, comportamentos e melhores práticas relacionadas com a análise do problema e com o processo de desenvolvimento de artefato são abrangidos (Bax, 2013).

A criação de artefatos de sucesso está fortemente relacionada à condução de pesquisas em *Design Science* em Sistemas de Informação (SI). Porém, a carência de uma metodologia que seja aceita e sirva de framework para pesquisas em *Design Science* e de um modelo para sua apresentação pode ter contribuído para a criação da *Design Science Research Methodology* (DSRM). A DSRM incorpora princípios, práticas e procedimentos necessários para realizar essas pesquisas e atende três objetivos: a) ser consistente com a literatura prévia; b) prover orientação para pesquisadores; e c) fornece um modelo mental para a apresentação dos resultados (Peffer et al., 2007)

A DSRM envolve um modelo de processo rigoroso que consiste em seis atividades (Peffer, 2007), as quais serão utilizadas nesta pesquisa. As atividades ocorrem de forma sequencial ou de acordo com a necessidade do projeto. A seguir, descreve-se brevemente cada uma dessas atividades:

- Atividade 1 - Identificação do problema e motivação: esta atividade é responsável pela definição do problema de pesquisa específico, assim como pela justificativa da importância da solução proposta;
- Atividade 2 - Definição dos objetivos da solução: esta atividade deduz os objetivos de uma solução a partir da definição do problema e do conhecimento do que é possível e viável executar;

- Atividade 3 - Projeto e desenvolvimento: esta atividade trata da criação do artefato. Inclui a determinação das funcionalidades desejadas do artefato, sua arquitetura e, em seguida, a criação do artefato real;
- Atividade 4 - Demonstração: esta atividade se preocupa com a demonstração do uso do artefato para resolver o problema. Isso implica no uso do artefato em experimentação, simulação, estudo de caso, prova ou outra atividade apropriada;
- Atividade 5 - Avaliação: esta atividade refere-se à observação e à medição do artefato para a solução do problema. Isso implica na comparação dos objetivos de uma solução com os resultados reais observados do uso do artefato na demonstração;
- Atividade 6 - Comunicação: esta atividade se destaca pela divulgação do problema e sua importância, assim como a apresentação do artefato produzido.

Em um primeiro momento, será realizado um levantamento bibliográfico abrangente sobre IA preditiva e análise de dados no contexto empresarial. Essa revisão tem como objetivo compreender os fundamentos teóricos e as técnicas atuais empregadas em previsões de negócios, incluindo métodos de ML e estatística utilizados para prever tendências de mercado, comportamento do consumidor, demanda, entre outros aspectos relevantes à gestão.

Posteriormente, pretende-se focar na coleta e estruturação de dados empresariais que sirvam de base para modelos preditivos. Serão investigadas fontes de dados internas (como histórico de vendas, indicadores financeiros, dados operacionais) e externas (por exemplo, dados de mercado ou econômicos) com potencial preditivo.

A eficácia de cada modelo será avaliada por meio de métricas quantitativas de acurácia preditiva e capacidade de generalização. Também serão realizados experimentos ou estudos de caso simulando cenários decisórios reais, a fim de verificar em que medida as previsões geradas poderiam apoiar os gestores na prática.

Nesta pesquisa será utilizada a (DSRM) para propor um modelo de IA preditiva voltado à tarefa de previsões em negócios a partir de fontes de dados não estruturados e estruturados na forma de texto. Para isso, será empregado o método proposto por Peffers (2007), o qual o quadro 2 evidencia os passos utilizados para a solução do problema.

Quadro 2. Processo das Etapas

Atividades	Descrição
Identificar o problema e motivação	Revisão bibliográfica da literatura.
Definir os objetivos para a solução	Revisão bibliográfica da literatura.
Projetar e desenvolver	Coleta de Dados: fontes de dados internas associados a histórico de vendas, indicadores financeiros, dados operacionais, referente aos últimos 6 meses.
	Pré-processamento: limpeza, padronização, tratamento de valores ausentes, normalização e estruturação em formato adequado para modelagem.
	Transformação dos dados: engenharia de atributos, extração de variáveis relevantes e preparação de séries temporais ou matrizes de entrada.
	Treinamento: Implementação de algoritmos de ML e métodos estatísticos adequados ao problema (ex.: regressão, árvores de decisão, modelos de séries temporais, redes neurais).
	Funcionalidades do artefato: geração de previsões, comparação entre modelos, e suporte visual (gráficos, tabelas) para interpretação gerencial.
Demonstração	Estudo de caso: previsões geradas pelo sistema são utilizadas para decisões como planejamento de vendas, controle financeiro ou previsão de demanda.
Avaliação	Utilização de métricas de acurácia e desempenho para avaliar a capacidade preditiva dos modelos. Comparação entre objetivos definidos e resultados obtidos. Análise da capacidade de generalização

	e discussão de limitações como qualidade dos dados, variabilidade do mercado e complexidade dos modelos.
Comunicação	Apresentação dos resultados, da relevância do problema e da contribuição do artefato, assim como a publicação de artigos.

Fonte: Elaborado pelo Autor (2025)

Ao final, os resultados obtidos serão analisados quanto à sua validade e utilidade, discutindo-se as limitações encontradas (como qualidade dos dados, complexidade dos modelos ou resistência organizacional) e propondo melhorias ou pesquisas futuras necessárias.

Revisão Ortográfica e Formatação		X	X	X	X	X	X	X	X	X	X	X	X
Entrega do Projeto de Pesquisa													X
Desenvolvimento da monografia		X	X	X			X	X	X	X	X	X	
Impressão e Encadernação													X
Defesa Publica						X							X

10 ORÇAMENTO

Despesas	Total
Materiais de expediente	R\$20,00
Fotocópias	R\$0,00
Impressões	R\$15,00
Encadernação	R\$50,00
Aquisição de bibliografia	R\$100,00
Total	R\$175,00

REFERENCIAS

- BAX, M. P. Design science: filosofia da pesquisa em ciência da informação e tecnologia. *Ciência da Informação*, v. 42, n. 2, p. 298-312, 2013.
- BRYNJOLFSSON, Erik; HITT, Lorin M.; KIM, Heekyung Hellen. Strength in Numbers: How Does Data-Driven Decisionmaking Affect Firm Performance? **SSRN Electronic Journal**, 2011.
- BURSTEIN, Frada; W. HOLSAPPLE, Clyde. **Handbook on Decision Support Systems 1**. Berlin, Heidelberg: Springer Berlin Heidelberg, 2008.
- CHOLLET, François. **Deep learning with Python**. Shelter Island, NY: Manning, 2018.
- GIL, A. C. Métodos e técnicas de pesquisa social. 6. ed. São Paulo: Atlas, 2008.
- GURKAYNAK, Gonenc; YILMAZ, Ilay; HAKSEVER, Gunes. Stifling artificial intelligence: Human perils. **Computer Law & Security Review**, v. 32, n. 5, p. 749–758, out. 2016.
- HEZAVEH, Yashar D.; LEVASSEUR, Laurence Perreault; MARSHALL, Philip J. Fast Automated Analysis of Strong Gravitational Lenses with Convolutional Neural Networks. **Nature**, v. 548, n. 7669, p. 555–557, ago. 2017.
- HUANG, Yanbo. Advances in Artificial Neural Networks – Methodological Development and Application. **Algorithms**, v. 2, n. 3, p. 973–1007, 3 ago. 2009.
- MOHRI, Mehryar; ROSTAMIZADEH, Afshin; TALWALKAR, Ameet. **Foundations of machine learning**. Second edition ed. Cambridge, MA: MIT Press, 2018.
- PEFFERS, Ken *et al.* A Design Science Research Methodology for Information Systems Research. **Journal of Management Information Systems**, v. 24, n. 3, p. 45–77, dez. 2007.
- PRIMAK, F. V. **Decisões com BI (Business Intelligence)**: Fabio Vinicius Primak, 2008.
- PROVOST, Foster; FAWCETT, Tom. Data Science and its Relationship to Big Data and Data-Driven Decision Making. **Big Data**, v. 1, n. 1, p. 51–59, mar. 2013.
- PROVOST, Foster; FAWCETT, Tom. *Data Science for Business*. 2013.
- RUSSELL, Stuart J.; NORVIG, Peter. **Artificial intelligence: a modern approach**. Fourth edition, global edition ed. Boston: Pearson, 2022.
- RUSU, Cristian *et al.* (ORGS.). **Transformación digital en la educación: innovaciones y desafíos**. [S.l.]: United Academic Journals (UA Journals), 2024.
- SHARDA, Ramesh; DELEN, Dursun; TURBAN, Efraim. **Business Intelligence e Análise de Dados para Gestão do Negócio - 4.ed. 1**: Bookman Editora, 2019.
- TEOFILI, Tommaso. **Deep Learning for Search**. New York: Manning Publications Co. LLC, 2019.

XU, Jun; HE, Xiangnan; LI, Hang. Deep Learning for Matching in Search and Recommendation. **Foundations and Trends® in Information Retrieval**, v. 14, n. 2–3, p. 102–288, 2020.